Plan de PFE

Prédiction de la maladie de Parkinson à l'aide du Machine Learning

El moufannane Yahya

Abdelkbir Zerouf

El gharbaoui Maroune

2024/2025

1. Introduction

- **Contexte** :

  La maladie de Parkinson est une pathologie neurodégénérative dont le diagnostic repose sur des critères cliniques subjectifs. Ce projet explore l'apport du Machine Learning (ML) pour une **détection précoce et objective**, via l'analyse de données vocales et/ou cliniques.

- **Problématique** :

  Comment le ML peut-il améliorer la précision et la rapidité du diagnostic de la maladie de Parkinson ?

2. Objectifs

- **Objectif général** :

  Développer un modèle de ML fiable pour prédire la présence de la maladie.

- **Objectifs spécifiques** :
  - Collecter et prétraiter des données pertinentes (ex : mesures vocales, biomarqueurs).
  - Comparer les performances d'algorithmes de ML (Random Forest, SVM, réseaux de neurones).
  - Identifier les caractéristiques les plus prédictives (ex : variations de fréquence vocale).

3. Méthodologie

3.1. Données

- **Sources** :

    - Jeu de données vocal **UCI ML Parkinson Dataset** (195 échantillons, 23 caractéristiques).
    - Données cliniques **PPMI** (si accès validé).
- **Prétraitement** :
    - Nettoyage (valeurs manquantes, normalisation).
    - Sélection de *features* (ANOVA, corrélations).
    - Réduction de dimension (PCA).

3.2. Modélisation

- **Algorithmes testés** :
    - **Classiques** : Régression logistique, SVM, Random Forest.
    - **Deep Learning** : MLP (Perceptron multicouche).
- **Validation** :
    - *Split* 70% train / 30% test.
    - Validation croisée (5 folds).
- **Évaluation** :
    - Métriques : Précision, AUC-ROC, F1-score.
    - Interprétabilité : Analyse SHAP/LIME.

4. Calendrier Prévisionnel

	Tâches
Semaine 1	Exploration des données + prétraitement.
Semaine 2	Développement et entraînement des modèles.
Semaine 3	Optimisation hyperparamètres + tests.
Semaine 4	Rédaction du rapport + préparation soutenance.

5. Risques et Solutions

- **Risque 1** : Données insuffisantes.

  Solution : Augmentation de données (SMOTE) ou transfer learning.

- **Risque 2** : Biais dans les données.

  Solution : Stratification lors du split train/test.

- **Risque 3** : Complexité des modèles.

  Solution : Utilisation de Google Colab pour la puissance de calcul.

6. Résultats Attendus

- Un modèle de ML avec une **précision > 85%**.
- Une comparaison détaillée des algorithmes (tableaux, courbes ROC).
- Un rapport de PFE clair et un dépôt GitHub du code source.

7. Points à Valider

1. Choix ou suggestions d'outils, langages, Framework et de technologies..
2. Choix d'interface(Frontend).
3. La pertinence des datasets choisis (UCI, PPMI).
4. La priorisation des algorithmes à implémenter.
5. Les attentes pour la soutenance (durée, format).
6. Choix de deploiement.